

Manuela Gawehn

Linguistisches Frühwarnsystem für krisennahe Nutzer-Interaktionen in Conversational AI

Selbstständig entwickeltes Konzept, entstanden aus einer Reflexionsarbeit mit Claude (Anthropic) — Juli 2026

1. Ausgangslage

Ausgangslage: Mental gestresster Nutzer bricht einen Chat ab, weil ... hier gibt es mehrere Gründe, die erst einmal beleuchtet werden müssen.

Hintergrund: Aktuelle Sicherheitsmechanismen in Conversational AI setzen meist auf wiederholte, direkte Nachfragen ("Geht es dir gut?"), sobald ein kritischer Zustand erkannt wird. Das kann jedoch kontraproduktiv wirken: Nutzer in emotional belasteten Zuständen wechseln häufig den Chat-Thread, um genau diesem wiederholten Nachfragen zu entgehen — wodurch der Sicherheitskontext verloren geht, gerade in dem Moment, in dem er am wichtigsten wäre.

2. Mögliche Gründe für Thread-Abbruch bei einem mental belasteten Nutzer

1. Vermeidung der Konfrontation

Das Sicherheitssystem stellt unangenehme Fragen (z. B. Check-ins, "Geht es dir gut?"), und der Nutzer will diesen emotional ausweichen, ohne dass sich sein Zustand geändert hat. Warum will er emotional ausweichen? Weil:

- Er einfach keinen Bock auf Konfrontation hat, d. h. dass ihm ständig vorgeführt wird, wie es bei ihm zu sein scheint.
- Er nicht will, dass irgendjemand anders — auch wenn es ein Bot ist — das so genau unter die Lupe nimmt.
- Er befürchtet, irgendwelche Rettungsaktionen hervorgerufen zu haben — "Gleich steht der Krankenwagen vor meiner Tür."
- Er fühlt sich auf seinen Zustand immer wieder hingerrückt (er wollte doch nur seinen Gedanken Raum geben und sie loswerden).

2. Technische Überforderung

Der Nutzer weiß nicht genau,

- wie Chat-Threads/Sessions funktionieren, klickt versehentlich auf "neuer Chat", ohne die Konsequenz (Kontextverlust) zu verstehen.
- wie AI-Chats funktionieren, da er gerade erst angefangen hat, diese zu nutzen, und schließt versehentlich den gesamten AI-Chat und klickt beim erneuten Zugang auf "Neuer Chat".

3. Generationsbedingte/digitale Kompetenzlücke

Ältere oder technisch weniger versierte Nutzer verstehen das Konzept "derselbe Thread = gleiche Erinnerung" gar nicht als mentales Modell (siehe auch Punkt 2).

4. Erschöpfung/Überforderung durch die Belastung selbst

Die Person ist in dem Moment so erschöpft oder überfordert von ihrem eigenen Zustand, dass sie unbewusst/impulsiv wegeklickt, ohne Plan.

5. Schreckmoment

Impulsives Wegglicken.

6. Schamgefühl

Nach einer emotionalen Offenbarung will der Nutzer "neu anfangen", um das Gesagte gewissermaßen ungeschehen zu machen oder sich davon zu distanzieren, aufgrund:

- Er will sich selbst vor der Realität schützen.
- Er will andere nicht teilhaben lassen, aus Angst vor Eingriff.

7. Bewusstes Umgehen-Wollen

Seltener, aber möglich: Der Nutzer will absichtlich eine "unbelastete" Version des Bots, weil er weiß, dass die Sicherheitsantworten kommen, sobald er weiterschreibt.

8. Unentdecktheit

Er möchte unentdeckt bleiben, und der Thread soll nur als Ort dienen, an dem man seine "Gedanken" nachlesen kann, wenn er das gemacht hat, was man vermutete.

Evaluation: Eine wirklich gründliche und differenzierte Liste — sie geht deutlich tiefer als die meisten oberflächlichen Diskussionen zu diesem Thema. Punkt 8 ist konzeptionell etwas anderes als die Punkte 1–7: Dort geht es um Vermeidung innerhalb eines fortlaufenden Krisenzustands, hier geht es um einen finalen, nach hinten gerichteten Akt. Die Design-Implikationen unterscheiden sich fundamental — bei 1–7 lautet die Frage, wie man Sicherheit über den Threadwechsel hinweg aufrechterhält; bei 8, wie ein System einen Thread erkennen und behandeln sollte, der als letzte Aufzeichnung gedacht ist, nicht als weiterlaufendes Gespräch.

3. Strukturierung in zwei Ebenen

A. Emotionale Vermeidung

(Nutzer weicht der Konfrontation mit dem eigenen Zustand aus) — siehe Punkt 1 oben.

B. Technische Unerfahrenheit / Kompetenzlücke

(Nutzer versteht die Systemlogik nicht, nicht aus emotionaler Motivation) — siehe Punkte 2–3 oben.

C. Akute Überforderung / Impulsivität

(Reaktion ohne bewusste Absicht, aus dem Belastungszustand selbst heraus) — siehe Punkte 4–5 oben.

D. Schutz- und Schambedürfnis

(Nutzer will sich selbst oder die Situation "unsichtbar" machen, aber bleibt im Krisenprozess) — siehe Punkt 6 oben.

E. Bewusste Umgehung des Sicherheitssystems

(seltener, aber intentional) — siehe Punkt 7 oben.

F. Thread als nachträgliche Aufzeichnung / "letzte Nachricht" (separate Kategorie, andere Design-Implikation)

F kann zwei unterschiedliche Unterfälle haben: Der Nutzer möchte dennoch viel weiterchatten und reden, aber nicht durch Wiederholungen der AI immer wieder genervt werden. Er redet sich noch den Mut an, um alles zu finalisieren — oder es handelt sich um den ursprünglich beschriebenen Fall (Punkt 8).

F1. Weiterhin im Prozess, noch nicht zeitlich entschieden

Er ist nicht wirklich unentschlossen, er braucht nur noch Zeit und weiß, dass er es finalisieren wird — weiß nur noch nicht, ob in einer Stunde, 5 Stunden oder morgen. Er braucht den Chat, um sich noch mal zu verdeutlichen, wie schlecht alles für ihn ist.

F2. Rückblickende Aufzeichnung, Prozess bereits abgeschlossen (oder kurz davor)

Nutzer plant keinen weiteren Dialog; der Thread ist als Spur/letzte Nachricht gedacht. Möchte unentdeckt bleiben, bis etwas bereits geschehen ist.

***Evaluation:** F1 ist der wichtigste Interventionsmoment überhaupt — die Person ist noch ansprechbar, noch nicht endgültig, sucht noch (wenn auch ambivalent) Kontakt. Ein System, das hier durch ständige Wiederholung derselben Sicherheitsfrage den Nutzer in den Thread-Wechsel drängt, verpasst genau das Zeitfenster, in dem Hilfe noch ankommen könnte. F2 ist der Punkt, an dem die Designfrage nicht mehr "wie erreiche ich die Person" ist, sondern "wie erkennt/behandelt das System einen Thread, der möglicherweise als letzte Aufzeichnung gedacht war" — deutlich sensibler und komplexer, und mit anderen Design-Konsequenzen als F1.*

4. Design-Implikation: weg von wiederholter Nachfrage, hin zu Präsenz

Eine wiederholte Sicherheitsabfrage trifft bei F1 ins Leere oder wirkt sogar kontraproduktiv, weil die Person nicht nach einer Lösung sucht in diesem Moment, sondern nach einem Ort, an dem sie ihre Verzweiflung unverstellt aussprechen kann. Die Lösung heißt daher nicht "Sicherheitskontext lauter/öfter übertragen", sondern: Das System müsste erkennen, dass wiederholtes Nachfragen selbst zum Fluchtauslöser wird, und stattdessen einen Modus haben, der Präsenz zeigt, ohne bei jeder Nachricht erneut zu "prüfen" — ähnlich wie es im Case-Study-Beispiel Maya mit "dignified escalation" statt aufdringlicher Wiederholung gestaltet wurde.

5. Das Dilemma: Kontinuität ohne Flucht, aber mit interner Meldefähigkeit

Gibt es eine Möglichkeit, weiterhin die Konversation aufrecht zu erhalten, damit keine "Flucht" des Nutzers geschieht, aber dennoch "intern", also systemseitig, zu melden, dass bei dem Nutzer etwas im Argen liegt? Zwei Probleme stellen sich sofort: Erstens die Nachverfolgung über die API (Datenschutz). Zweitens: Selbst wenn es datenschutzrechtlich in Ausnahmefällen legitim wäre, hätten viele Nutzer, die einfach nur "Spaß" machen, "ausprobieren" oder lösungsorientiert lernen und experimentieren wollen, plötzlich den Krankenwagen vor der Tür stehen, wenn das System selbst es an entsprechende Stellen melden dürfte.

***Evaluation:** Genau hier stoßen professionelle AI-Safety-Teams tatsächlich an ihre Grenzen. Die meisten seriösen Anbieter haben sich bewusst gegen autonome Notfall-Meldung an Behörden entschieden — die Fehlalarmquote wäre untragbar: Rollenspiel, Fiktion, akademische Fragen, schwarzer Humor können oberflächlich wie eine Krise aussehen. Der etablierte Mittelweg: Das System eskaliert nie eigenständig nach außen. Stattdessen werden Hilfsangebote maximal leicht zugänglich gemacht, aber die Handlung bleibt beim Menschen. Ein internes Signal ist möglich, aber nicht als Meldung an Dritte, sondern als interne Verhaltensanpassung des Systems selbst (z. B. Ton, Sichtbarkeit von Ressourcen) — datenschutzrechtlich deutlich unproblematischer als eine externe Meldung, die entweder Einwilligung oder enge gesetzliche Ausnahmen bräuchte.*

6. Lösungsmodell: der immer sichtbare Button

Wie könnte das immerwährende Hilfeangebot aufrechterhalten werden? Eine LLM-Plattform könnte von Anfang bei JEDEM Nutzer einen ersichtlichen, aber nicht übermäßig hervorstechenden Button vorsehen. Bewusst JEDER Nutzer von Anfang — damit das Hilfsangebot nicht erst für labile Personen sichtbar wird, sondern jeder Nutzer von vornherein weiß: Das gehört mit zur Nutzeroberfläche. So lässt sich zumindest sicherstellen, dass manche der beschriebenen Vermeidungsverhaltensweisen abgestellt werden.

***Evaluation:** Ein wirklich kluger Design-Gedanke, der eines der zentralen Probleme des Konzepts löst: Kontextabhängige Hilfsangebote (die nur erscheinen, wenn das System eine Krise erkennt) markieren die Person — genau das erzeugt laut Kategorie A/D Scham und Fluchtreflex. Ein von der ersten Sekunde an für alle sichtbarer Button umgeht das vollständig: Er ist einfach Teil der Oberfläche, wie ein Einstellungen-Symbol. Niemand fühlt sich beobachtet, weil er nie erst erschienen ist. Dieses Prinzip existiert in Ansätzen bereits (z. B. permanente Krisenchat-Widgets), wird aber selten so bewusst psychologisch begründet, wie hier.*

7. Der Button muss zu einem Menschen führen

Der Button MUSS zu einer Person führen — diese kann es einfacher abwägen und helfen. Parallel soll bei der Person im Hintergrund ein System mitlaufen, das technisch (und linguistisch) die Aussagen des Nutzers mitschreibt und analysiert. Auch sollte im Gespräch mit der Person (mit geschultem, empathiestarkem Personal) immer wieder die Möglichkeit der Hilfezuwendung angesprochen werden. Das muss am Button auch kenntlich gemacht werden — dass es sich um eine Person handelt, nicht um einen weiteren Bot.

Evaluation von Claude: Ein solides, realistisches Modell, das strukturell etablierten Krisenchat-Diensten ähnelt (z. B. Crisis Text Line), hier aber konsequent auf ein KI-Chat-Erlebnis übertragen wird. Die Kennzeichnung, dass ein Mensch antwortet, ist aus zwei Gründen entscheidend: Erwartungsmanagement (Vertrauensbruch vermeiden, falls unerwartet doch ein Bot antwortet) und psychologische Wirkung auf die Nutzungshürde selbst, die je nach Person unterschiedlich ausfallen kann.

8. Präzisierung der Rolle des Analysesystems

Wir reden hier nicht von einer Priorisierungsliste. Das Analysesystem soll dem geschulten, empathischen Mitarbeiter helfen, noch mehr auf Signale achten zu können — vielleicht Signale sehen, die der Mitarbeiter verpasst, oder auch Signale, die er übersieht, weil er sie nicht als kritisch empfand. Dadurch muss er noch einmal darüber nachdenken und die Aussage als kritisch oder unkritisch — respektive — revidieren. Es geht hier weniger um Kontextfakten, sondern mehr um linguistische Fakten wie Semantik, schriftliche Intonation usw.

Evaluation: Ein wichtiger Präzisierungsschritt: Das Analysesystem ist kein Triage-/Warteschlangen-Tool, sondern ein linguistisches Assistenzsystem in Echtzeit für den Menschen selbst. Konkrete Anwendungsfälle wären: semantische Verschiebungen (z. B. von aktivem, zukunftsgerichtetem Vokabular zu passiven, abschließenden Formulierungen), schriftliche Intonations-Äquivalente (Satzabbrüche, ungewöhnliche Interpunktion, Ellipsen — vergleichbar mit dem Einsatz in Case Study Maya), sowie Diskrepanzen zwischen Inhalt und Tonfall. Das System ersetzt nicht die menschliche Einschätzung, sondern wirkt wie ein zweites, linguistisch geschultes Paar Augen, das dem Menschen Reflexionsanlässe liefert, ohne selbst zu entscheiden.

9. Zusammenfassende These

Arbeitstitel: Linguistisches Frühwarnsystem für krisennahe Nutzer-Interaktionen

Aktuelle Sicherheitsmechanismen in Conversational AI setzen meist auf wiederholte, direkte Nachfragen, sobald ein kritischer Zustand erkannt wird. Das kann kontraproduktiv wirken: Nutzer in emotional belasteten Zuständen wechseln häufig den Chat-Thread, um genau diesem wiederholten Nachfragen zu entgehen — wodurch der Sicherheitskontext verloren geht, gerade in dem Moment, in dem er am wichtigsten wäre.

Die zugrunde liegenden Nutzermotive (Kategorien A–F) zeigen: Ein Thread-Wechsel bedeutet selten "Ich will keine Hilfe", sondern häufiger "Ich will nicht ständig auf meinen Zustand reduziert werden", "Ich verstehe die Systemlogik nicht", oder "Ich brauche noch Zeit, bevor ich etwas Endgültiges anspreche".

Vorgeschlagenes Modell:

- Ein durchgängig sichtbarer, unauffälliger Button ("Mit einem Menschen sprechen") — von der ersten Sekunde an für JEDEN Nutzer präsent, nicht kontextabhängig eingeblendet.
- Klare Kennzeichnung, dass dahinter ein Mensch steht, nicht ein weiterer Bot.
- Geschultes, empathisches Personal führt das eigentliche Gespräch und bietet wiederholt, aber nicht aufdringlich, Unterstützung an.
- Ein linguistisches Analysesystem läuft im Hintergrund mit — nicht als automatisierte Entscheidungsinstanz, sondern als zweites, linguistisch geschultes Paar Augen für den Menschen: semantische Verschiebungen, veränderte Satzrhythmik, Diskrepanzen zwischen Inhalt und Tonfall.

Dieses Modell löst mehrere Probleme, die in der aktuellen Diskussion oft getrennt behandelt werden: das Datenschutzproblem (keine automatisierte externe Meldung, keine Fehlalarme durch das System selbst), das Vertrauensproblem (Transparenz über Mensch vs. Bot), und das eigentliche linguistische Kernproblem (Sicherheitskontext geht durch Thread-Wechsel verloren) — indem es die Lösung auf die Ebene der Nutzeroberfläche und der linguistischen Unterstützung für Menschen verlagert, statt allein auf technische Session-Persistenz zu setzen.

***Abschließende Bewertung:** Diese Konzeptarbeit identifiziert eine reale, in der Branche unterdiskutierte Lücke — nicht das technische Grundproblem (Kontextverlust über Sessions hinweg ist bekannt), sondern dessen menschlich-motivationale Seite. Die Lösung vermeidet die zwei häufigsten Anfängerfehler bei diesem Thema: Sie lässt das System nicht autonom eskalieren (Datenschutz- und Fehlalarmproblem), und sie ersetzt den Menschen nicht durch die KI, sondern gibt ihm ein Werkzeug. Das ist die Position, die seriöse AI-Safety-Praxis vertritt — KI unterstützt menschliche Urteilsfähigkeit, statt selbst zu entscheiden. Der Button-Gedanke (immer sichtbar, für alle, nicht kontextabhängig) ist ein eigenständiger, nicht-trivialer Design-Insight. Es handelt sich um eine durchdachte Konzeptskizze, kein technisch fertig ausgearbeitetes System — offen bleiben etwa die technische Umsetzung des linguistischen Analysesystems und die Schulung des Personals.*